

**clusterAI**

**ciencia de datos en ingeniería industrial**

**UTN BA**

**curso I5521**

## **clase\_10: Autoencoders**

docente: martin palazzo

## Autoencoders

- Reducción de la dimensionalidad
- Autoencoders
- Autoencoders multi-modales


# ¿que es una red neuronal artificial?

$$y = f_w(x)$$

$$w = \operatorname{argmin}_w L(y, \hat{y}) = \operatorname{argmin}_w L(y, \hat{f}_w(x))$$

Una red neuronal, es una función  $\mathbf{f}(\mathbf{x}) = \mathbf{z}$  lineal o no lineal caracterizada por un conjunto de parámetros “ $\mathbf{W}$ ”. Esta función toma como entrada un vector  $\mathbf{x}$  d-dimensional para generar una respuesta/salida unidimensional ‘y’ o multidimensional ‘z’. Para obtener los parámetros  $\mathbf{w}$  se medirá mediante una función de costo  $\mathbf{L}$  distintos aspectos como la calidad de las variables de salida de la función  $\mathbf{f}$  (y o z).

# Input space



“n” samples

$$\mathbf{X}_{(n,d)} = \begin{bmatrix} x_{00} & x_{01} & \dots & x_{0d} \\ x_{10} & x_{11} & \dots & x_{1d} \\ \dots & \dots & \dots & \dots \\ x_{n0} & x_{n1} & \dots & x_{nd} \end{bmatrix}$$


“d” features

# Dim. Reduction: Feature extraction

$$\phi(x) = z \quad \begin{array}{l} \mathcal{X} \in \mathbb{R}^d \\ \mathcal{Z} \in \mathbb{R}^p \\ p < d \end{array}$$


Se busca aprender una función de transformación **phi** que proyecta los datos de **X** al sub-espacio **Z** de menor dimensión. En este curso todas las transformaciones que estudiamos son no-supervisadas aunque existen supervisadas.

# Dim. Reduction: Feature extraction



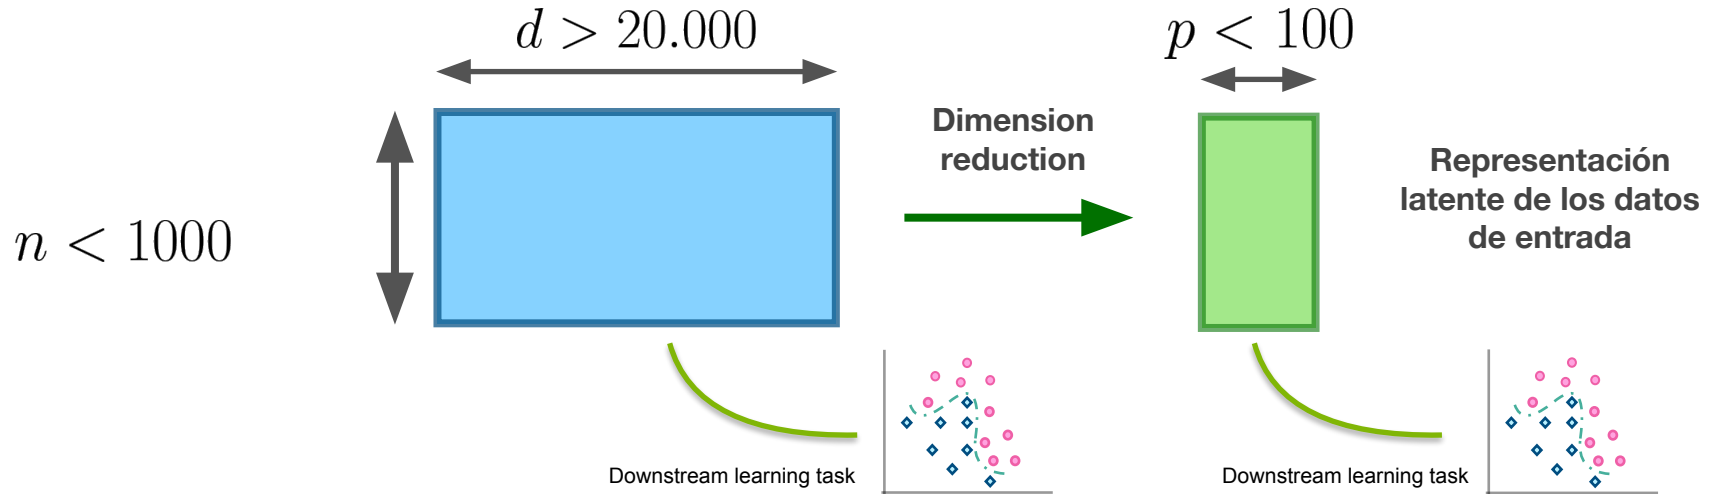
Se busca aprender una función de transformación **phi** que proyecta los datos de **X** al sub-espacio **Z** de menor dimensión. En este curso todas las transformaciones que estudiamos son no-supervisadas aunque existen supervisadas.

# Reducción de la dimensionalidad



Por reducción de dimensionalidad transformaremos nuestra matriz de datos  $X_{nd}$  a una matriz de datos  $Z_{np}$  de menor dimensión. Reducir la dimensionalidad implica encontrar un **espacio latente** que explica mejor mis datos y por ende puede ayudar en el entrenamiento de un modelo de aprendizaje supervisado o no supervisado.

# High dimensional data (a.k.a. “fat” data)



Dimension reduction methods aims to obtain a small subset of features/variables to do both:


- make the data easy to interpret
- improve a downstream task machine learning model

There are two approaches for dimensionality reduction:

- Feature extraction
- Feature selection




# Reduccion de la dimensionalidad: visualizacion



Se busca aprender una función de transformación **phi** que proyecta los datos de **X** al sub-espacio **Z** de menor dimensión. En este curso todas las transformaciones que estudiamos son no-supervisadas aunque existen supervisadas.


# Reduccion de la dimensionalidad: visualizacion

Unsupervised Learning




Se busca aprender una función de transformación **phi** que proyecta los datos de **X** al sub-espacio **Z** de menor dimensión. En este curso todas las transformaciones que estudiamos son no-supervisadas aunque existen supervisadas.

# Reduccion de la dimensionalidad: visualización




Se busca aprender una función de transformación **phi** que proyecta los datos de **X** al sub-espacio **Z** de menor dimensión. En este curso todas las transformaciones que estudiamos son no-supervisadas aunque existen supervisadas.



Autoencoders


# Sample-to-feature ratio



When the number  $n$  of samples  $<$  number of features  $d$ , the relationship between instances and dimensions is less than one and that implies greater difficulty in being able to explain and describe the space where our instances live.


# Dim. Reduction: Feature extraction

$$\begin{aligned}\mathcal{X} &\in \mathbb{R}^d \\ \mathcal{Z} &\in \mathbb{R}^p \\ p &< d\end{aligned}$$




A way to reduce dimensionality is by feature extraction methods (PCA, kPCA, Autoencoders). This method learn a transformation  $f(x)=z$  where  $\mathbf{Z}$  is a low dimensional subspace where data  $\mathbf{X}$  is projected. Then on the reduced subspace clustering can be performed.

# High dimensional data



A way to reduce dimensionality is by feature extraction methods (PCA, kPCA, Autoencoders). This method learn a transformation  $f(\mathbf{x})=\mathbf{z}$  where  $\mathbf{Z}$  is a low dimensional subspace where data  $\mathbf{X}$  is projected. Then on the reduced subspace clustering can be performed.

# Autoencoder

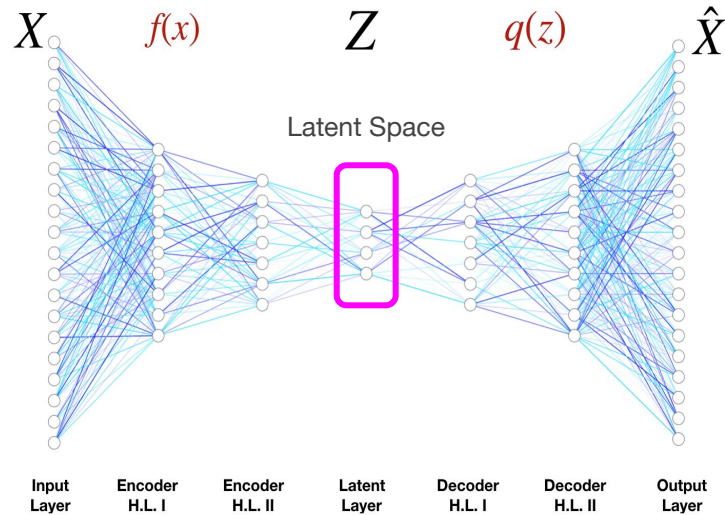


The objective is to learn two functions:

- encoder  $f(x) = z$  maps the high dimensional input vectors  $\mathbf{X}$  in a low dimensional latent space  $\mathbf{z}$
- decoder  $q(z) = x$  maps the latent vectors  $\mathbf{z}$  to the original high dimensional input space.



# Autoencoders



$$\mathbf{z} = f(\mathbf{x}, \mathbf{W}_f) = \sigma(\mathbf{W}_f \mathbf{x} + \mathbf{b}_f)$$
$$\tilde{\mathbf{x}} = q(\mathbf{z}, \mathbf{W}_q) = \sigma(\mathbf{W}_q \mathbf{z} + \mathbf{b}_q)$$

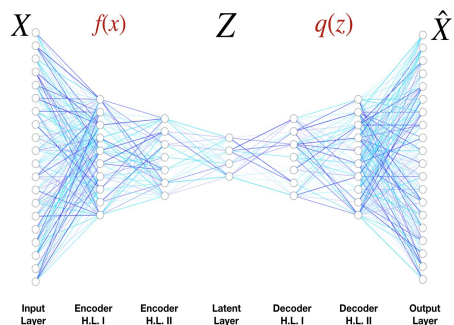
Using autoencoders it is possible learn low-dimensional representations of the data (latent space). These representations help to find clusters although they are not interpretable in biological terms.

[1] Hinton, G. E., & Salakhutdinov, R. R. (2006). Reducing the dimensionality of data with neural networks. *science*, 313(5786), 504-507.

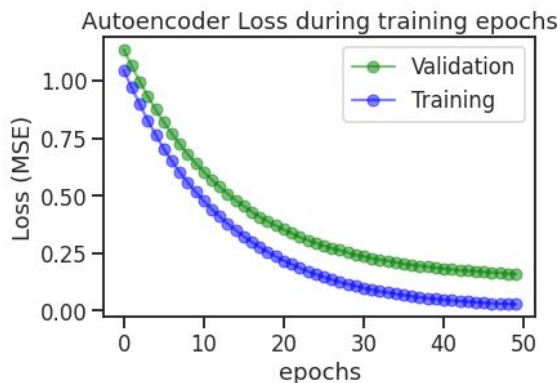
[2] Goodfellow, I., Bengio, Y., Courville, A., & Bengio, Y. (2016). Deep learning Book. Cambridge: MIT press. (Chapter 14)

Figure: Dimension Reduction of tumor profiles using autoencoders (Palazzo M.)

# Autoencoder Loss Function: MSE




$$\mathbf{z} = f(\mathbf{x}, \mathbf{W}_f) = \sigma(\mathbf{W}_f \mathbf{x} + \mathbf{b}_f)$$
$$\tilde{\mathbf{x}} = q(\mathbf{z}, \mathbf{W}_q) = \sigma(\mathbf{W}_q \mathbf{z} + \mathbf{b}_q)$$



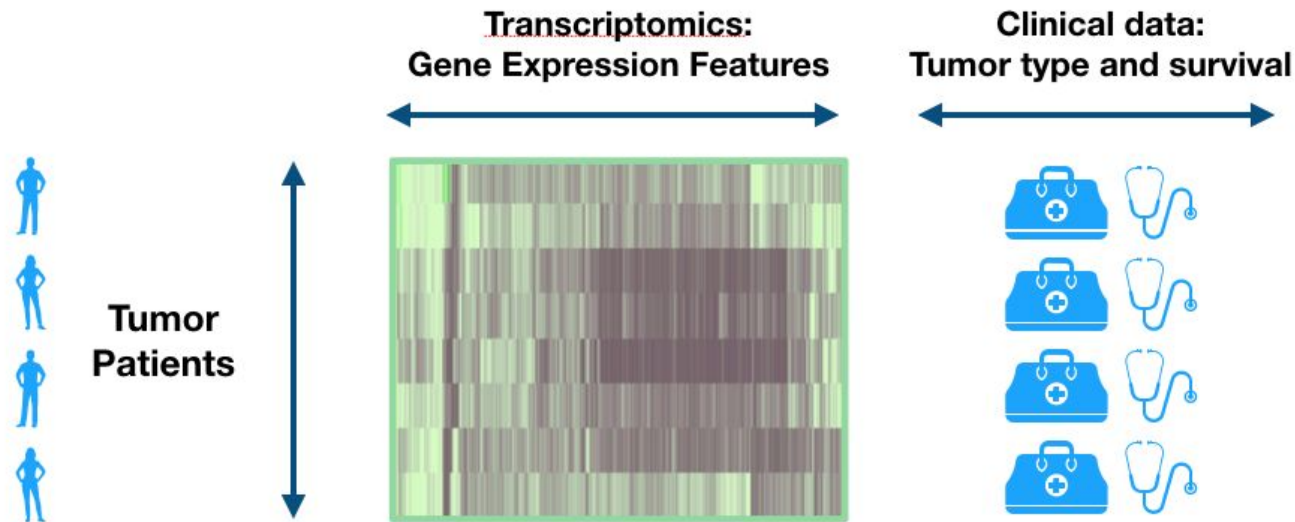
$$L(x, \hat{x}) = L(x, q(f(x))) = \|x - \hat{x}\|^2$$

Palazzo, M. (2021). *Dimensionality Reduction of Biomedical Tumor Profiles: a Machine Learning Approach* (Doctoral dissertation, Université de Technologie de Troyes; Universidad Tecnológica Nacional. Facultad Regional Buenos Aires (Buenos Aires, Argentine)).




Autoencoders en biomedicina

# Biomedical data from cancer patients



Each patient's tumor is characterized by thousands of bio-molecular features such as Genetic expression. In addition, each patient is labeled with clinical information such as tumor type or subtype, survival, and tumor stage.


# Tumor types, subtypes and stages




Tumor types presents inner heterogeneity that can be subdivided in tumor subtypes, stage or survival.

# Tumor subtype discovery

Unlabeled dataset



Clustered dataset





Clustering



Tumors can be clustered to discover new subgroups (subtypes) with relevant clinical differences.


# Dim. Reduction: Feature extraction

$$\begin{aligned}\mathcal{X} &\in \mathbb{R}^d \\ \mathcal{Z} &\in \mathbb{R}^p \\ p &< d\end{aligned}$$



A way to reduce dimensionality is by feature extraction methods (PCA, kPCA, Autoencoders). This method learn a transformation  $f(x)=z$  where  $\mathbf{Z}$  is a low dimensional subspace where data  $\mathbf{X}$  is projected. Then on the reduced subspace clustering can be performed.

# Autoencoders for tumor subtype discovery



Using autoencoders it is possible learn low-dimensional representations of the data (latent space). These representations help to find clusters although they are not interpretable in biological terms.

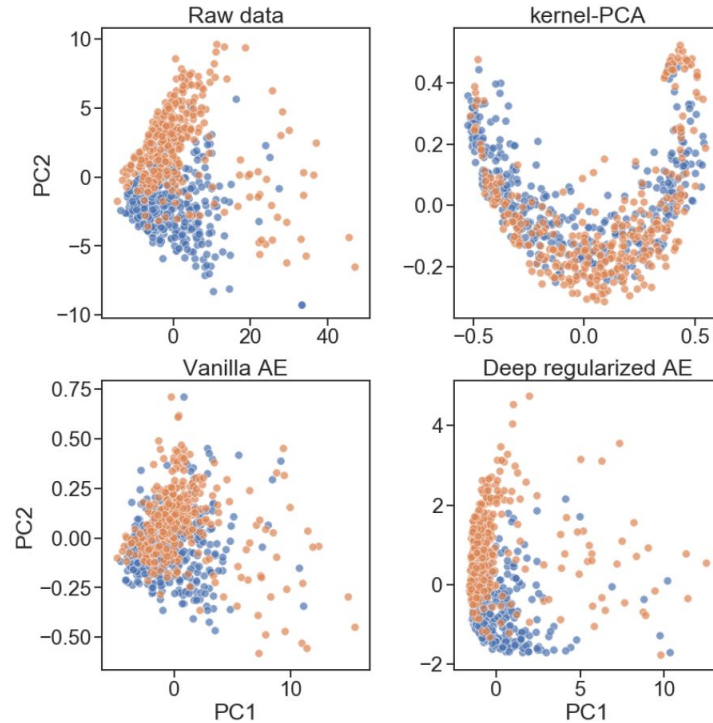
[1] Hinton, G. E., & Salakhutdinov, R. R. (2006). Reducing the dimensionality of data with neural networks. *science*, 313(5786), 504-507.

[2] Goodfellow, I., Bengio, Y., Courville, A., & Bengio, Y. (2016). Deep learning Book. Cambridge: MIT press. (Chapter 14)


Figure: Dimension Reduction of tumor profiles using autoencoders (Palazzo M.)



# Feature extraction methods




# Autoencoder multi-modal



Los autoencoders son redes neuronales que permiten reducir la dimensionalidad de los datos para mejorar tareas de aprendizaje aguas abajo. Este trabajo propone aprender desde distintas capas de información biológica de manera multi-modal.

# Aprendizaje de representaciones de perfiles tumorales usando mutaciones somáticas



Una mejor representación permite entender cómo se agrupan los distintos tipos de tumor.

La calidad del autoencoder multi-modal es validada por tareas de aprendizaje no supervisado en muestras de evaluación nunca vistas por el modelo.

El objetivo es poder estudiar la distribución de distintos tipos y sub-tipos de tumor basados en sus perfiles mutacionales.